

Biwm Calculations

Leonardo Uchoa

Conteúdo do documento

Neste documento estão presentes todas as contas feitas para a implementação da estimação por máxima verossimilhança do modelo Matérn Bivariado proposto por Gneiting. Aqui aproveita-se a estrutura de blocos da matriz de covariância cruzada para melhor estimar os parâmetros.

Formulação

Para o modelo (Cressie)

$$\mathbf{Y}^*(\mathbf{s}) = \mu(\mathbf{s}) + \eta(\mathbf{s}) + \epsilon(\mathbf{s}) \quad (1)$$

temos que $\mathbf{s} \in \mathbb{R}^2$ e que

- $\mu(\mathbf{s})$ é a variação determinística (de grande escala);
- $\eta(\mathbf{s})$ é o efeito aleatório espacial (variação de pequena escala, dependente da resolução dos dados);
- $\epsilon(\mathbf{s})$ é a variação em escala micro (não detectável na resolução (condicional) dos dados).

Agora adapta-se esta formulação para o cenário multivariado

$$\mathbf{Y}^*(\mathbf{s}) = \boldsymbol{\mu}(\mathbf{s}) + \boldsymbol{\eta}(\mathbf{s}) + \boldsymbol{\epsilon}(\mathbf{s}) \quad (2)$$

em que novamente $\mathbf{s} \in \mathbb{R}^2$, e

- $\boldsymbol{\mu}(\mathbf{s})$ é o vetor de variações determinísticas (de grande escala);
- $\boldsymbol{\eta}(\mathbf{s})$ é o vetor de efeitos aleatórios espaciais (variações de pequena escala, dependentes da resolução dos dados);
- $\boldsymbol{\epsilon}(\mathbf{s})$ é o vetor de variações em escala micro (não detectáveis na resolução (condicional) dos dados).

de forma que o processo \mathbf{Y} é bivariado com a seguinte estrutura

$$\mathbf{Y}^*(\mathbf{s}) = \begin{pmatrix} Y_{11}(\mathbf{s}) & Y_{12}(\mathbf{s}) \\ \vdots & \vdots \\ Y_{N1}(\mathbf{s}) & Y_{N2}(\mathbf{s}) \end{pmatrix} \quad (3)$$

Neste ponto a estratégia é modelar as observações bivariadas do processo espacial por meio de uma Normal Bivariada. Ou seja, cada par de observações $(Y_{i1}(\mathbf{s}), Y_{i2}(\mathbf{s}))$ seria uma realização de $N_2(\boldsymbol{\mu}, \Sigma)$, indexada (de alguma maneira) no espaço. Para isto é interessante reformular a equação (3) em termos da função $\text{Vec}(\cdot)$:

$$\mathbf{Y}(\mathbf{s}) := Vec(\mathbf{Y}^*(\mathbf{s})) = \begin{pmatrix} Y_{11}(\mathbf{s}) \\ Y_{12}(\mathbf{s}) \\ \vdots \\ Y_{N1}(\mathbf{s}) \\ Y_{N2}(\mathbf{s}) \end{pmatrix} \quad (4)$$

em que atribui-se ao processo $\mathbf{Y}(\mathbf{s})$ a distribuição Normal Multivariada com vetor de funções médias $\boldsymbol{\mu}^T(\mathbf{s}) = (\mu_1(\mathbf{s}), \mu_2(\mathbf{s}))$ e função de covariância cruzada $\boldsymbol{\Sigma}(\mathbf{h})$ com estrutura dada por

$$\boldsymbol{\Sigma}(\mathbf{h}) = \begin{pmatrix} C_{11}(\mathbf{h}) & C_{12}(\mathbf{h}) \\ C_{21}(\mathbf{h}) & C_{22}(\mathbf{h}) \end{pmatrix} \quad (5)$$

Assume-se também estacionariedade de segunda ordem para este processo, onde as funções médias não dependem das localizações e as funções de covariâncias simples e cruzadas só dependem da distância entre as observações. Isto é

$$\begin{aligned} E(Y_{i1}^*(\mathbf{s} + \mathbf{h})) &= E(Y_{i1}(\mathbf{s})) = \mu_1 \\ E(Y_{i2}^*(\mathbf{s} + \mathbf{h})) &= E(Y_{i2}(\mathbf{s})) = \mu_2 \\ E(Y_{i2}^*(\mathbf{s} + \mathbf{h})Y_{i2}^*(\mathbf{s})) &= C_{11}(\|\mathbf{s}-\mathbf{h}\|) \\ E(Y_{i1}^*(\mathbf{s} + \mathbf{h})Y_{i2}^*(\mathbf{s})) &= C_{22}(\|\mathbf{s}-\mathbf{h}\|) \\ E(Y_{i2}^*(\mathbf{s} + \mathbf{h})Y_{i1}^*(\mathbf{s})) &= C_{12}(\|\mathbf{s}-\mathbf{h}\|) \\ E(Y_{i1}^*(\mathbf{s} + \mathbf{h})Y_{i2}^*(\mathbf{s})) &= C_{21}(\|\mathbf{s}-\mathbf{h}\|) \end{aligned} \quad (6)$$

Neste momento postulam-se funções para estruturar $C_{ij}(\mathbf{s})$. Aqui as funções serão Matérn, formuladas de forma que a sua composição em $\boldsymbol{\Sigma}(\mathbf{h})$, dita $\boldsymbol{\Sigma}_{\boldsymbol{\theta}}(\mathbf{h})$ com $\boldsymbol{\theta} = (\boldsymbol{\sigma}, \mathbf{a}, \boldsymbol{\nu}, \mu)$, formam a função de covariância Matérn Bivariada. Neste momento restringe-se ao modelo reduzido (parsimonioso) que induz às funções de covariâncias e covariâncias cruzadas

$$\begin{aligned} C_{11}(\mathbf{h}) &= \sigma_1^2 M(\mathbf{h}|a, \nu_1) \\ C_{22}(\mathbf{h}) &= \sigma_2^2 M(\mathbf{h}|a, \nu_2) \\ C_{12}(\mathbf{h}) &= \rho_{12} \sigma_1 \sigma_2 M(\mathbf{h}|a, (\nu_1 + \nu_2)/2) \\ M(\mathbf{h}|\nu, a) &= \frac{2^{1-\nu} (a\mathbf{h})^\nu K_\nu(a\mathbf{h})}{\Gamma(\nu)} \end{aligned}$$

onde $\boldsymbol{\theta} = (\sigma_1, \sigma_2, a, \mu_1, \mu_2)$. Toda esta formulação nos permite escrever a log-verossimilhança do processo como a de uma normal multivariada

$$l(\boldsymbol{\theta}) = -1/2 (\log(|\boldsymbol{\Sigma}_{\boldsymbol{\theta}}|) + \mathbf{x}^t \boldsymbol{\Sigma}_{\boldsymbol{\theta}}^{-1} \mathbf{x} + 2N \log(2\pi)) \quad (7)$$

Derivadas

Fórmula Geral da Derivada da Log-verossimilhança

Ao derivarmos 7 em relação a qualquer elemento, θ , de $\boldsymbol{\theta}$, temos a expressão geral da derivada da log-verossimilhança:

$$\frac{\partial l(\boldsymbol{\theta})}{\partial \theta} = tr \left(\boldsymbol{\Sigma}_{\boldsymbol{\theta}}^{-1} \frac{\partial \boldsymbol{\Sigma}_{\boldsymbol{\theta}}}{\partial \theta} \right) - \mathbf{x}^t \left[\boldsymbol{\Sigma}_{\boldsymbol{\theta}}^{-1} \frac{\partial \boldsymbol{\Sigma}_{\boldsymbol{\theta}}}{\partial \theta} \boldsymbol{\Sigma}_{\boldsymbol{\theta}}^{-1} \right] \mathbf{x}. \quad (8)$$

Então se $y = \mathbf{x}\Sigma_{\boldsymbol{\theta}}^{-1}$, pela simetria da função de covariância Matérn Bivariada tem-se que

$$\frac{\partial l(\boldsymbol{\theta})}{\partial \boldsymbol{\theta}} = \text{tr}\left(\Sigma_{\boldsymbol{\theta}}^{-1} \frac{\partial \Sigma_{\boldsymbol{\theta}}}{\partial \boldsymbol{\theta}}\right) - \mathbf{y}^t \left[\frac{\partial \Sigma_{\boldsymbol{\theta}}}{\partial \boldsymbol{\theta}} \right] \mathbf{y}. \quad (9)$$

Derivada das Funções de Covariâncias

Para obter $\partial \Sigma_{\boldsymbol{\theta}} / \partial \boldsymbol{\theta}$, onde $\boldsymbol{\theta} = (\sigma_1^2, \sigma_2^2, a, \rho, \mu_1, \mu_2)$, vamos utilizar a regra da cadeia passo a passo.

Derivada de $\Sigma_{\boldsymbol{\theta}}$ c.r.a σ_1^2

$$\frac{\partial \Sigma_{\boldsymbol{\theta}}(\mathbf{h})}{\partial \sigma_1^2} = \begin{pmatrix} M(\mathbf{h}|\nu_1, a) & \\ \frac{\rho\sigma_2}{2\sigma_1} M(\mathbf{h}|\frac{\nu_1+\nu_2}{2}, a) & \mathbf{O} \end{pmatrix} \quad (10)$$

Derivada de $\Sigma_{\boldsymbol{\theta}}$ c.r.a σ_2^2

$$\frac{\partial \Sigma_{\boldsymbol{\theta}}(\mathbf{h})}{\partial \sigma_2^2} = \begin{pmatrix} \mathbf{O} & \\ \frac{\rho\sigma_1}{2\sigma_2} M(\mathbf{h}|\frac{\nu_1+\nu_2}{2}, a) & M(\mathbf{h}|\nu_2, a) \end{pmatrix} \quad (11)$$

Derivada de $\Sigma_{\boldsymbol{\theta}}$ c.r.a ρ

$$\frac{\partial \Sigma_{\boldsymbol{\theta}}(\mathbf{h})}{\partial \rho} = \begin{pmatrix} \mathbf{O} & \\ \sigma_1\sigma_2 M(\mathbf{h}|\frac{\nu_1+\nu_2}{2}, a) & \mathbf{O} \end{pmatrix} \quad (12)$$

Derivada de $\Sigma_{\boldsymbol{\theta}}$ c.r.a a

Neste caso temos que

$$\frac{\partial \Sigma_{\boldsymbol{\theta}}(\mathbf{h})}{\partial a} = \begin{pmatrix} \sigma_1^2 \psi_1 & \rho \sigma_1^2 \sigma_2^2 \psi_3 \\ \rho \sigma_1^2 \sigma_2^2 \psi_3 & \sigma_2^2 \psi_2 \end{pmatrix} \quad (13)$$

onde ψ_k é a derivada de $\partial M(\mathbf{h}|\nu_k, a)$ c.r.a a para $k = 1, 2, 3$, em que $\nu_3 = (\nu_1 + \nu_2)/2$. Agora

$$\frac{\partial M(\mathbf{h}|\nu, a)}{\partial a} = \frac{2^{1-\nu} d^\nu}{\Gamma(\nu)} \left[\nu a^{\nu-1} K_\nu(ad) + a^\nu \frac{\partial K_\nu(ad)}{\partial a} \right] \quad (14)$$

e, como

$$\frac{\partial K_\nu(ad)}{\partial a} = d \left[\frac{\nu}{ad} K_\nu(ad) - K_{\nu+1}(ad) \right] \quad (15)$$

então

$$\frac{\partial M(\mathbf{h}|\nu, a)}{\partial a} = \frac{2^{1-\nu} d^\nu}{\Gamma(\nu)} \left[\nu a^{\nu-1} K_\nu(ad) + a^\nu d \left(\frac{\nu}{ad} K_\nu(ad) - K_{\nu+1}(ad) \right) \right]. \quad (16)$$

Ao simplificar a última equação, obtem-se que

$$\psi_i = \frac{2^{1-\nu_i} d^{\nu_i} a^{\nu_i-1}}{\Gamma(\nu_i)} \left[2\nu_i K_{\nu_i}(ad) - ad K_{\nu_i+1}(ad) \right] \quad (17)$$

Estrutura de Blocos para Contas na Log-Verossimilhança

Log do Determinante

Todas as contas a seguir tem o intuito de melhorar problemas de instabilidade numérica, reduzir o custo computacional de inversas.

Se

$$\Sigma_{\theta}(\mathbf{h}) = \begin{pmatrix} C_{11}(\mathbf{h}) & C_{12}(\mathbf{h}) \\ C_{21}(\mathbf{h}) & C_{22}(\mathbf{h}) \end{pmatrix} \quad (18)$$

Então

$$\det(\Sigma) = |\Sigma| = \left| C_{11}(\mathbf{h}) - C_{12}(\mathbf{h})C_{22}^{-1}(\mathbf{h})C_{21}(\mathbf{h}) \right| * \left| C_{22}(\mathbf{h}) \right| \quad (19)$$

Portanto, com o logaritmo fica

$$\log(\det(\Sigma)) = \log \left| C_{11}(\mathbf{h}) - C_{12}(\mathbf{h})C_{22}^{-1}(\mathbf{h})C_{21}(\mathbf{h}) \right| + \log \left| C_{22}(\mathbf{h}) \right| \quad (20)$$

Inversa

Aqui existem duas formas. Eu preferi usar a que irei apresentar a seguir pois ela encaixa bem com o resultado (20) do log do determinante¹.

Se

$$\Sigma_{\theta}^{-1}(\mathbf{h}) = \begin{pmatrix} C_{11}^{*}(\mathbf{h}) & C_{12}^{*}(\mathbf{h}) \\ C_{21}^{*}(\mathbf{h}) & C_{22}^{*}(\mathbf{h}) \end{pmatrix} \quad (21)$$

Então

$$\begin{aligned} C_{11}^{*}(\mathbf{h}) &= \left[C_{11}(\mathbf{h}) - C_{12}(\mathbf{h})C_{22}^{-1}(\mathbf{h})C_{21}(\mathbf{h}) \right]^{-1} \\ C_{12}^{*}(\mathbf{h}) &= - \left[C_{11}(\mathbf{h}) - C_{12}(\mathbf{h})C_{22}^{-1}(\mathbf{h})C_{21}(\mathbf{h}) \right]^{-1} C_{12}(\mathbf{h})C_{22}^{-1}(\mathbf{h}) \\ C_{21}^{*}(\mathbf{h}) &= -C_{22}^{-1}(\mathbf{h})C_{21}(\mathbf{h}) \left[C_{11}(\mathbf{h}) - C_{12}(\mathbf{h})C_{22}^{-1}(\mathbf{h})C_{21}(\mathbf{h}) \right]^{-1} \\ C_{22}^{*}(\mathbf{h}) &= C_{22}^{-1}(\mathbf{h}) + C_{22}^{-1}(\mathbf{h})C_{21}(\mathbf{h}) \left[C_{11}(\mathbf{h}) - C_{12}(\mathbf{h})C_{22}^{-1}(\mathbf{h})C_{21}(\mathbf{h}) \right]^{-1} C_{12}(\mathbf{h})C_{22}^{-1}(\mathbf{h}) \end{aligned} \quad (22)$$

Já que² $C_{12}(\mathbf{h}) = C_{21}^T(\mathbf{h})$, se definirmos

$$\begin{aligned} V_1 &:= C_{22}^{-1}(\mathbf{h})C_{21}(\mathbf{h}) \\ V_2 &:= C_{11}(\mathbf{h}) - C_{12}(\mathbf{h})C_{22}^{-1}(\mathbf{h})C_{21}(\mathbf{h}) \end{aligned} \quad (23)$$

¹Apesar de eu achar que não tem como o alimentar o optim com as inversas obtidas, para ganhar tempo

²No artigo Σ é definida assim

podemos obter uma forma simplificada para o sistema (22), já que como $C_{11}, C_{12}, C_{21}, C_{22}$ são simétricas

$$\begin{aligned} C_{11}^*(\mathbf{h}) &= V_2^{-1} \\ C_{12}^*(\mathbf{h}) &= -V_2^{-1}V_1^T \\ C_{21}^*(\mathbf{h}) &= -V_1V_2^{-1} \\ C_{22}^*(\mathbf{h}) &= C_{22}^{-1}(\mathbf{h}) - V_1V_2^{-1}V_1^T \end{aligned} \quad (24)$$

pois $V_1 = C_{22}^{-1}(\mathbf{h})C_{21}(\mathbf{h})$ fornece $V_1^T = C_{12}(\mathbf{h})C_{22}^{-1}(\mathbf{h})$.

Note ainda que $C_{12}^*(\mathbf{h}) = C_{21}^{*T}(\mathbf{h})$.

Prova:

Primeiramente

$$\begin{aligned} V_2^T &= C_{11}(\mathbf{h}) - (C_{12}(\mathbf{h})C_{22}^{-1}(\mathbf{h})C_{12}(\mathbf{h}))^T \\ &= C_{11}(\mathbf{h}) - C_{12}(\mathbf{h})(C_{12}(\mathbf{h})C_{22}^{-1}(\mathbf{h}))^T \\ &= C_{11}(\mathbf{h}) - C_{12}(\mathbf{h})C_{22}^{-1}(\mathbf{h})C_{12}(\mathbf{h}) \\ &= V_2 \end{aligned} \quad (25)$$

Agora

$$\begin{aligned} C_{12}^{*T}(\mathbf{h}) &= -(V_2^{-1}V_1^T)^T \\ &= V_1^T(V_2^{-1})^T \\ &= V_1^T(V_2^{-1}) \\ &= C_{21}^*(\mathbf{h}) \end{aligned} \quad (26)$$

Avaliação de Σ^{-1} na log-verossimilhança

Neste caso precisamos avaliar $y^T \Sigma^{-1} y$. A estrutura de blocos também pode nos ajudar a deixar o algoritmo um pouco mais estável e rápido.

Novamente a inversa de Σ é denotada por

$$\Sigma_{\theta}^{-1}(\mathbf{h}) = \begin{pmatrix} C_{11}^*(\mathbf{h}) & C_{12}^*(\mathbf{h}) \\ C_{21}^*(\mathbf{h}) & C_{22}^*(\mathbf{h}) \end{pmatrix} \quad (27)$$

Agora se $y^T = (y_1, y_2)^T$, em que y_1 e y_2 são, respectivamente, os vetores resposta associados às primeira e segunda variáveis multivariadas, temos que

$$\begin{aligned} y^T \Sigma_{\theta}^{-1}(\mathbf{h}) y &= y^T \begin{pmatrix} C_{11}^*(\mathbf{h}) & C_{12}^*(\mathbf{h}) \\ C_{21}^*(\mathbf{h}) & C_{22}^*(\mathbf{h}) \end{pmatrix} y \\ &= (y_1, y_2)^T \begin{pmatrix} C_{11}^*(\mathbf{h}) & C_{12}^*(\mathbf{h}) \\ C_{21}^*(\mathbf{h}) & C_{22}^*(\mathbf{h}) \end{pmatrix} \begin{pmatrix} y_1 \\ y_2 \end{pmatrix} \\ &= (y_1, y_2)^T \begin{pmatrix} C_{11}^*(\mathbf{h})y_1 + C_{12}^*(\mathbf{h})y_2 \\ C_{21}^*(\mathbf{h})y_1 + C_{22}^*(\mathbf{h})y_2 \end{pmatrix} \\ &= y_1^T C_{11}^*(\mathbf{h})y_1 + y_1^T C_{12}^*(\mathbf{h})y_2 + y_2^T C_{21}^*(\mathbf{h})y_1 + y_2^T C_{22}^*(\mathbf{h})y_2 \\ &= y_1^T C_{11}^*(\mathbf{h})y_1 + 2y_1^T C_{12}^*(\mathbf{h})y_2 + y_2^T C_{22}^*(\mathbf{h})y_2 \end{aligned} \quad (28)$$

pois como $C_{12}^{*T}(\mathbf{h}) = C_{21}^*(\mathbf{h})$ obtemos que

$$y_1^T C_{12}^*(\mathbf{h}) y_2 = \text{tr}(y_1^T C_{12}^*(\mathbf{h}) y_2) = \text{tr}(y_1^T C_{12}^*(\mathbf{h}) y_2)^T = \text{tr}((C_{12}^*(\mathbf{h}) y_2)^T y_1) = \text{tr}(y_2^T C_{12}^{*T}(\mathbf{h}) y_1) = y_2^T C_{21}^*(\mathbf{h}) y_1$$

Também é possível escrever o resultado anterior em termos de (28), o que fornece

$$y_1^T V_2^{-1} y_1 - 2y_1^T V_2^{-1} V_1^T y_2 + y_2^T C_{22}^{-1} y_2 - y_2^T V_1 V_2^{-1} V_1^T y_2$$

Estrutura de Blocos para Contas no Gradiente

Aqui a idéia é mitigar o custo computacional de $\text{tr}\left(\Sigma_{\theta}^{-1}(\mathbf{h}) \frac{\partial \Sigma}{\partial \theta_k}\right) + y^T \left[\frac{\partial \Sigma(\mathbf{h})}{\partial \theta_k}\right] y$ já que vão aparecer muitas matrizes nulas bem grandes em $\partial \Sigma / \partial \theta_k$

Relembrar é viver: Produto de Matrizes

Se

$$\Sigma_{\theta}(\mathbf{h}) = \begin{pmatrix} C_{11}(\mathbf{h}) & C_{12}(\mathbf{h}) \\ C_{21}(\mathbf{h}) & C_{22}(\mathbf{h}) \end{pmatrix} \quad (29)$$

e

$$\mathbf{M} = \begin{pmatrix} A & B \\ C & D \end{pmatrix} \quad (30)$$

Então desde as matrizes \mathbf{M} e $\Sigma_{\theta}(\mathbf{h})$ sejam conformes

$$\Sigma_{\theta}(\mathbf{h}) \mathbf{M} = \begin{pmatrix} C_{11}(\mathbf{h})A + C_{12}(\mathbf{h})C & C_{11}(\mathbf{h})B + C_{12}(\mathbf{h})D \\ C_{21}(\mathbf{h})A + C_{22}(\mathbf{h})C & C_{21}(\mathbf{h})B + C_{22}(\mathbf{h})D \end{pmatrix} \quad (31)$$

Caso em que $\theta_k = \sigma_1^2$

Traço

$$\begin{aligned} \Sigma_{\theta}^{-1}(\mathbf{h}) \frac{\partial \Sigma}{\partial \sigma_1^2} &= \begin{pmatrix} C_{11}^*(\mathbf{h}) & C_{12}^*(\mathbf{h}) \\ C_{21}^*(\mathbf{h}) & C_{22}^*(\mathbf{h}) \end{pmatrix} \begin{pmatrix} M(\mathbf{h}|\nu_1, a) & \\ \frac{\rho\sigma_2}{2\sigma_1} M(\mathbf{h}|\nu_3, a) & \mathbf{O} \end{pmatrix} \\ &= \begin{pmatrix} C_{11}^*(\mathbf{h})M(\mathbf{h}|\nu_1, a) + C_{12}^*(\mathbf{h})\frac{\rho\sigma_2}{2\sigma_1} M(\mathbf{h}|\nu_3, a) & C_{11}^*(\mathbf{h})\frac{\rho\sigma_2}{2\sigma_1} M(\mathbf{h}|\nu_3, a) \\ C_{21}^*(\mathbf{h})M(\mathbf{h}|\nu_1, a) + C_{22}^*(\mathbf{h})\frac{\rho\sigma_2}{2\sigma_1} M(\mathbf{h}|\nu_3, a) & C_{21}^*(\mathbf{h})\frac{\rho\sigma_2}{2\sigma_1} M(\mathbf{h}|\nu_3, a) \end{pmatrix} \end{aligned} \quad (32)$$

Portanto como $C_{12}^*(\mathbf{h}) = C_{21}^{*T}(\mathbf{h})$

$$\begin{aligned} \text{tr}\left(\Sigma_{\theta}^{-1}(\mathbf{h}) \frac{\partial \Sigma}{\partial \sigma_1^2}\right) &= \text{tr}\left(C_{11}^*(\mathbf{h})M(\mathbf{h}|\nu_1, a)\right) + 2\text{tr}\left(C_{12}^*(\mathbf{h})\frac{\rho\sigma_2}{2\sigma_1} M(\mathbf{h}|\nu_3, a)\right) \\ &= \text{tr}\left(C_{11}^*(\mathbf{h})M(\mathbf{h}|\nu_1, a)\right) + \frac{\rho\sigma_2}{\sigma_1} \text{tr}\left(C_{12}^*(\mathbf{h})M(\mathbf{h}|\nu_3, a)\right) \\ &= \frac{1}{\sigma_1^2} \text{tr}\left(C_{11}^*(\mathbf{h})C_{11}(\mathbf{h})\right) + \frac{1}{\sigma_1^2} \text{tr}\left(C_{12}^*(\mathbf{h})C_{12}(\mathbf{h})\right) \\ &= \frac{1}{\sigma_1^2} \left[\text{tr}\left(C_{11}^*(\mathbf{h})C_{11}(\mathbf{h})\right) + \text{tr}\left(C_{12}^*(\mathbf{h})C_{12}(\mathbf{h})\right) \right] \end{aligned} \quad (33)$$

Forma Quadrática

$$\begin{aligned}
y^T \left[\frac{\partial \Sigma(\mathbf{h})}{\partial \theta_k} \right] y &= (y_1^T \quad y_2^T) \begin{pmatrix} M(\mathbf{h}|\nu_1, a) & \\ \rho \frac{\sigma_2}{2\sigma_1} M(\mathbf{h}|\nu_3, a) & \mathbf{O} \end{pmatrix} \begin{pmatrix} y_1 \\ y_2 \end{pmatrix} \\
&= (y_1^T \quad y_2^T) \begin{pmatrix} M(\mathbf{h}|\nu_1, a)y_1 + \rho \frac{\sigma_2}{2\sigma_1} M(\mathbf{h}|\nu_3, a)y_2 \\ \rho \frac{\sigma_2}{2\sigma_1} M(\mathbf{h}|\nu_3, a)y_1 \end{pmatrix} \\
&= y_1^T M(\mathbf{h}|\nu_1, a)y_1 + y_1^T \rho \frac{\sigma_2}{2\sigma_1} M(\mathbf{h}|\nu_3, a)y_2 + y_2^T \rho \frac{\sigma_2}{2\sigma_1} M(\mathbf{h}|\nu_3, a)y_1 \\
&= y_1^T M(\mathbf{h}|\nu_1, a)y_1 + \rho \frac{\sigma_2}{\sigma_1} y_1^T M(\mathbf{h}|\nu_3, a)y_2 \\
&= \frac{1}{\sigma_1^2} y_1^T \left[C_{11}(\mathbf{h}|\nu_1, a)y_1 + C_{12}(\mathbf{h}|\nu_3, a)y_2 \right]
\end{aligned} \tag{34}$$

Caso em que $\theta_k = \sigma_2^2$

Traço

$$\begin{aligned}
\Sigma_{\theta}^{-1}(\mathbf{h}) \frac{\partial \Sigma}{\partial \sigma_2^2} &= \begin{pmatrix} C_{11}^*(\mathbf{h}) & C_{12}^*(\mathbf{h}) \\ C_{21}^*(\mathbf{h}) & C_{22}^*(\mathbf{h}) \end{pmatrix} \begin{pmatrix} \mathbf{O} & \\ \rho \frac{\sigma_1}{2\sigma_2} M(\mathbf{h}|\nu_3, a) & M(\mathbf{h}|\nu_2, a) \end{pmatrix} \\
&= \begin{pmatrix} C_{12}^*(\mathbf{h}) \rho \frac{\sigma_1}{2\sigma_2} M(\mathbf{h}|\nu_3, a) & C_{11}^*(\mathbf{h}) \rho \frac{\sigma_1}{2\sigma_2} M(\mathbf{h}|\nu_3, a) + C_{12}^*(\mathbf{h}) M(\mathbf{h}|\nu_2, a) \\ C_{22}^*(\mathbf{h}) \rho \frac{\sigma_1}{2\sigma_2} M(\mathbf{h}|\nu_3, a) & C_{21}^*(\mathbf{h}) \rho \frac{\sigma_1}{2\sigma_2} M(\mathbf{h}|\nu_3, a) + C_{22}^*(\mathbf{h}) M(\mathbf{h}|\nu_2, a) \end{pmatrix}
\end{aligned} \tag{35}$$

Portanto como $C_{12}^*(\mathbf{h}) = C_{21}^{*T}(\mathbf{h})$

$$\begin{aligned}
tr \left(\Sigma_{\theta}^{-1}(\mathbf{h}) \frac{\partial \Sigma}{\partial \sigma_2^2} \right) &= tr \left(C_{22}^*(\mathbf{h}) M(\mathbf{h}|\nu_2, a) \right) + 2tr \left(C_{12}^*(\mathbf{h}) \rho \frac{\sigma_1}{2\sigma_2} M(\mathbf{h}|\nu_3, a) \right) \\
&= tr \left(C_{22}^*(\mathbf{h}) M(\mathbf{h}|\nu_2, a) \right) + \frac{\rho \sigma_1}{\sigma_2} tr \left(C_{12}^*(\mathbf{h}) M(\mathbf{h}|\nu_3, a) \right) \\
&= \frac{1}{\sigma_2^2} tr \left(C_{22}^*(\mathbf{h}) C_{22}(\mathbf{h}) \right) + \frac{1}{\sigma_2^2} tr \left(C_{12}^*(\mathbf{h}) C_{12}(\mathbf{h}) \right) \\
&= \frac{1}{\sigma_2^2} \left[tr \left(C_{22}^*(\mathbf{h}) C_{22}(\mathbf{h}) \right) + tr \left(C_{12}^*(\mathbf{h}) C_{12}(\mathbf{h}) \right) \right]
\end{aligned} \tag{36}$$

Forma Quadrática

$$\begin{aligned}
y^T \left[\frac{\partial \Sigma(\mathbf{h})}{\partial \theta_k} \right] y &= (y_1^T \quad y_2^T) \begin{pmatrix} \mathbf{O} & \\ \rho \frac{\sigma_1}{2\sigma_2} M(\mathbf{h}|\nu_3, a) & M(\mathbf{h}|\nu_2, a) \end{pmatrix} \begin{pmatrix} y_1 \\ y_2 \end{pmatrix} \\
&= (y_1^T \quad y_2^T) \begin{pmatrix} \rho \frac{\sigma_1}{2\sigma_2} M(\mathbf{h}|\nu_3, a)y_2 \\ \rho \frac{\sigma_1}{2\sigma_2} M(\mathbf{h}|\nu_3, a)y_1 + M(\mathbf{h}|\nu_2, a)y_2 \end{pmatrix} \\
&= y_2^T M(\mathbf{h}|\nu_1, a)y_2 + y_1^T \rho \frac{\sigma_1}{2\sigma_2} M(\mathbf{h}|\nu_3, a)y_2 + y_2^T \rho \frac{\sigma_1}{2\sigma_2} M(\mathbf{h}|\nu_3, a)y_1 \\
&= y_2^T M(\mathbf{h}|\nu_1, a)y_2 + \rho \frac{\sigma_1}{\sigma_2} y_1^T M(\mathbf{h}|\nu_3, a)y_2 \\
&= \frac{1}{\sigma_2^2} \left[y_2^T C_{22}(\mathbf{h}|\nu_1, a) + y_1^T C_{12}(\mathbf{h}|\nu_3, a) \right] y_2
\end{aligned} \tag{37}$$

Caso em que $\theta_k = \rho$

Traço

$$\begin{aligned}\Sigma_{\theta}^{-1}(\mathbf{h}) \frac{\partial \Sigma}{\partial \rho} &= \begin{pmatrix} C_{11}^*(\mathbf{h}) & C_{12}^*(\mathbf{h}) \\ C_{21}^*(\mathbf{h}) & C_{22}^*(\mathbf{h}) \end{pmatrix} \begin{pmatrix} \mathbf{O} & \\ \sigma_1 \sigma_2 M(\mathbf{h}|\nu_3, a) & \mathbf{O} \end{pmatrix} \\ &= \begin{pmatrix} C_{12}^*(\mathbf{h}) \sigma_1 \sigma_2 M(\mathbf{h}|\nu_3, a) & C_{11}^*(\mathbf{h}) \sigma_1 \sigma_2 M(\mathbf{h}|\nu_3, a) \\ C_{22}^*(\mathbf{h}) \sigma_1 \sigma_2 M(\mathbf{h}|\nu_3, a) & C_{21}^*(\mathbf{h}) \sigma_1 \sigma_2 M(\mathbf{h}|\nu_3, a) \end{pmatrix}\end{aligned}\quad (38)$$

Portanto como $C_{12}^*(\mathbf{h}) = C_{21}^{*T}(\mathbf{h})$

$$tr \left(\Sigma_{\theta}^{-1}(\mathbf{h}) \frac{\partial \Sigma}{\partial \rho} \right) = 2\sigma_1 \sigma_2 tr \left(C_{12}^*(\mathbf{h}) M(\mathbf{h}|\nu_3, a) \right) \quad (39)$$

Forma Quadrática

$$\begin{aligned}y^T \left[\frac{\partial \Sigma(\mathbf{h})}{\partial \theta_k} \right] y &= (y_1^T \quad y_2^T) \begin{pmatrix} \mathbf{O} & \\ \sigma_1 \sigma_2 M(\mathbf{h}|\nu_3, a) & \mathbf{O} \end{pmatrix} \begin{pmatrix} y_1 \\ y_2 \end{pmatrix} \\ &= (y_1^T \quad y_2^T) \begin{pmatrix} \sigma_1 \sigma_2 M(\mathbf{h}|\nu_3, a) y_2 \\ \sigma_1 \sigma_2 M(\mathbf{h}|\nu_3, a) y_1 \end{pmatrix} \\ &= y_1^T \sigma_1 \sigma_2 M(\mathbf{h}|\nu_3, a) y_2 + y_2^T \sigma_1 \sigma_2 M(\mathbf{h}|\nu_3, a) y_1 \\ &= 2\sigma_1 \sigma_2 y_1^T M(\mathbf{h}|\nu_3, a) y_2\end{aligned}\quad (40)$$

Caso em que $\theta_k = a$

Traço

$$\begin{aligned}\Sigma_{\theta}^{-1}(\mathbf{h}) \frac{\partial \Sigma}{\partial a} &= \begin{pmatrix} C_{11}^*(\mathbf{h}) & C_{12}^*(\mathbf{h}) \\ C_{21}^*(\mathbf{h}) & C_{22}^*(\mathbf{h}) \end{pmatrix} \begin{pmatrix} \sigma_1^2 M'(\mathbf{h}|\nu_1, a) & \rho \sigma_1 \sigma_2 M'(\mathbf{h}|\nu_3, a) \\ \rho \sigma_1 \sigma_2 M'(\mathbf{h}|\nu_3, a) & \sigma_2^2 M'(\mathbf{h}|\nu_2, a) \end{pmatrix} \\ &= \begin{pmatrix} C_{11}^*(\mathbf{h}) \sigma_1^2 M'(\mathbf{h}|\nu_1, a) + C_{12}^*(\mathbf{h}) \rho \sigma_1 \sigma_2 M'(\mathbf{h}|\nu_3, a) & C_{11}^*(\mathbf{h}) \rho \sigma_1 \sigma_2 M'(\mathbf{h}|\nu_3, a) + C_{12}^*(\mathbf{h}) \sigma_2^2 M'(\mathbf{h}|\nu_2, a) \\ C_{21}^*(\mathbf{h}) \sigma_1^2 M'(\mathbf{h}|\nu_1, a) + C_{22}^*(\mathbf{h}) \rho \sigma_1 \sigma_2 M'(\mathbf{h}|\nu_3, a) & C_{21}^*(\mathbf{h}) \rho \sigma_1 \sigma_2 M'(\mathbf{h}|\nu_3, a) + C_{22}^*(\mathbf{h}) \sigma_2^2 M'(\mathbf{h}|\nu_2, a) \end{pmatrix}\end{aligned}\quad (41)$$

Portanto como $C_{12}^*(\mathbf{h}) = C_{21}^{*T}(\mathbf{h})$

$$\begin{aligned}tr \left(\Sigma_{\theta}^{-1}(\mathbf{h}) \frac{\partial \Sigma}{\partial a} \right) &= \sigma_1^2 tr \left(C_{11}^*(\mathbf{h}) M'(\mathbf{h}|\nu_1, a) \right) + \\ &\quad \sigma_2^2 tr \left(C_{22}^*(\mathbf{h}) M'(\mathbf{h}|\nu_2, a) \right) + \\ &\quad 2\rho \sigma_1 \sigma_2 tr \left(C_{12}^*(\mathbf{h}) M'(\mathbf{h}|\nu_3, a) \right)\end{aligned}\quad (42)$$

Por outro lado, temos que

$$M'(\mathbf{h}|\nu, a) = \frac{\partial M(\mathbf{h}|\nu, a)}{\partial a} = \frac{(\frac{2}{a})^{1-\nu} d^\nu}{\Gamma(\nu)} \left[2\nu K_\nu(ad) - ad K_{\nu+1}(ad) \right] \quad (43)$$

em que $d := \|\mathbf{h}\|$.

Forma Quadrática

$$\begin{aligned}
y^T \left[\frac{\partial \Sigma(\mathbf{h})}{\partial \theta_k} \right] y &= \begin{pmatrix} y_1^T & y_2^T \end{pmatrix} \begin{pmatrix} \sigma_1^2 M'(\mathbf{h}|\nu_1, a) & \rho \sigma_1 \sigma_2 M'(\mathbf{h}|\nu_3, a) \\ \rho \sigma_1 \sigma_2 M'(\mathbf{h}|\nu_3, a) & \sigma_2^2 M'(\mathbf{h}|\nu_2, a) \end{pmatrix} \begin{pmatrix} y_1 \\ y_2 \end{pmatrix} \\
&= \begin{pmatrix} y_1^T & y_2^T \end{pmatrix} \begin{pmatrix} \sigma_1^2 M'(\mathbf{h}|\nu_1, a) y_1 + \rho \sigma_1 \sigma_2 M'(\mathbf{h}|\nu_3, a) y_2 \\ \rho \sigma_1 \sigma_2 M'(\mathbf{h}|\nu_3, a) y_1 + \sigma_2^2 M'(\mathbf{h}|\nu_2, a) y_2 \end{pmatrix} \\
&= y_1^T \sigma_1^2 M'(\mathbf{h}|\nu_1, a) y_1 + y_1^T \rho \sigma_1 \sigma_2 M'(\mathbf{h}|\nu_3, a) y_2 + y_2^T \rho \sigma_1 \sigma_2 M'(\mathbf{h}|\nu_3, a) y_1 + y_2^T \sigma_2^2 M'(\mathbf{h}|\nu_2, a) y_2 \\
&= \sigma_1^2 y_1^T M'(\mathbf{h}|\nu_1, a) y_1 + \sigma_2^2 y_2^T M'(\mathbf{h}|\nu_2, a) y_2 + 2 \rho \sigma_1 \sigma_2 y_1^T M'(\mathbf{h}|\nu_3, a) y_2
\end{aligned} \tag{44}$$